

WCCM 2026 — Speaker Script

Development of a Defect Estimation Method for CFRP Interstage Structures with Holes using FEA and Graph Neural Networks

Keisuke Nishioka et al. — 17th WCCM / ECCOMAS 2026, Munich (MS090E). Spoken English on top, Japanese translation below. ~12 min.

Slide 1 — Title

Good morning, everyone. My name is Keisuke Nishioka, from Keio University and Leibniz University Hannover, and I am presenting joint work with co-authors at Nagoya University and JAXA. The title is: Development of a Defect Estimation Method for CFRP Interstage Structures with Holes, using Finite Element Analysis and Graph Neural Networks. In short, I will show how we can localize hidden delamination inside perforated carbon-fiber composite structures, using only a surface stress measurement together with a graph neural network. We reach sixty-one percent macro-F1 from surface data alone, and I will also show how we make the method robust to realistic measurement noise.

【和訳】おはようございます。慶應義塾大学およびライプニッツ大学ハノーファーの西岡佳祐です。名古屋大学・JAXA の共著者との共同研究を発表します。題目は「有限要素解析とグラフニューラルネットワークを用いた、孔あき CFRP 段間構造の欠陥推定法の開発」です。要は、表面の応力測定とグラフニューラルネットワークだけで、孔あき炭素繊維複合材の内部に隠れた層間剥離を位置標定できることを示します。表面データのみで macro-F1 61%を達成し、さらに現実的な測定ノイズへの頑健化も示します。

Slide 2 — Outline

Here is the roadmap for the talk. I will start with the motivation and our measurement principle — the infrared stress field we call DSPSS. Then I will describe the method: how we pre-process the input, and the graph attention network we build on the finite-element mesh. I will give the published results: a nineteen-class three-dimensional localization at sixty-one percent macro-F1. After that I will present the new work for this congress: robustness to measurement noise using defect-free negatives. And I will close with the outlook.

【和訳】発表の流れです。まず動機と測定原理 — DSPSS と呼ぶ赤外応力場 — から始めます。次に手法：入力の前処理と、有限要素メッシュ上に構築するグラフアテンションネットワーク。続いて既発表の結果：19 クラスの 3 次元位置標定で macro-F1 61%。その後、本会議向けの新規部分：欠陥なし負例を用いた測定ノイズ頑健化。最後に今後の展望で締めます。

Slide 3 — Contributions

Let me state the three contributions up front. First, a graph attention network that localizes three-dimensional delamination in perforated CFRP interstage structures, directly from the finite-element surface stress field. Second, sixty-one percent macro-F1 over nineteen classes — that is, in-plane region times insertion layer — from surface data only, while keeping the false-negative rate on defect nodes below three percent. And third, a noise-robust training scheme, combining structured noise with defect-free negatives, as a concrete step toward using real experimental infrared-stress data.

【和訳】3 つの貢献を先に述べます。第一に、有限要素の表面応力場から直接、孔あき CFRP 段間構造の 3 次元層間剥離を位置標定するグラフアテンションネットワーク。第二に、表面データのみで 19 クラス（面内領域 × 挿入層）の macro-F1 61%を達成し、欠陥ノードの偽陰性率を 3%未満に抑えたこと。第三に、構造化ノイズと欠陥なし負例を組み合わせたノイズ頑健な学習法で、実際の赤外応力データ活用への具体的な一歩です。

Slide 4 — Introduction: CFRP in space transportation

Why does this matter? Carbon-fiber reinforced plastic is the primary structural material in reusable launch vehicles, because of its high specific strength. But around the bolt holes of these structures, interlaminar delamination accumulates with repeated use, and it is completely invisible from the outside. Conventional non-destructive testing — ultrasonic scanning, X-ray CT, or tap testing — is slow, expensive, and strongly operator-dependent. So there is a real need for an automated, reliable way to localize these sub-surface defects.

【和訳】なぜ重要か。炭素繊維強化プラスチックは比強度が高く、再使用型ロケットの主要構造材です。しかしボルト孔まわりでは繰り返し使用により層間剥離が蓄積し、外からは全く見えません。従来の非破壊検査——超音波、X線CT、打音法——は遅く高価で、作業依存性が強い。したがって、この表面下欠陥を自動かつ信頼性高く位置標定する手法が真に必要です。

Slide 5 — Infrared stress measurement (DSPSS)

Our measurable quantity is an infrared stress measurement. Through the thermoelastic effect, a small temperature change is proportional to the change in the sum of principal stresses. So an infrared camera gives us a full-field surface map of that stress sum, which we abbreviate as DSPSS. The key point is that a sub-surface defect perturbs this surface stress field and creates a local stress valley, visible on the right. That valley is the signal we exploit.

【和訳】測定量は赤外応力測定です。熱弾性効果により、微小な温度変化は主応力和の変化に比例します。よって赤外カメラから応力和の全視野表面マップが得られ、これを DSPSS と略します。要点は、表面下の欠陥がこの表面応力場を乱し、右図のような局所的な応力の谷を生むこと。この谷こそ我々が利用する信号です。

Slide 6 — Previous study and purpose

What was done before, and why is ours harder? Kojima and colleagues gave a convolutional-network proof of concept, but on non-perforated, simple CFRP coupons. Our setting is substantially harder on three counts: the structure is a perforated interstage; we estimate the full three-dimensional location, meaning both the in-plane region and the through-thickness layer; and the problem is extremely imbalanced, with defect nodes under three percent. Formally, we learn a node classifier on the mesh graph, where each node carries its coordinates and the normalized stress, and we minimize a focal loss. Class zero is defect-free, and classes one through eighteen encode region times layer.

【和訳】従来研究と、なぜ我々の方が難しいか。児嶋らは畳み込みネットの概念実証を、孔なしの単純な CFRP クーポンで示しました。我々の設定は3点で格段に難しい：構造が孔あき段間であること、面内領域と板厚方向の層の両方を含む完全な3次元位置を推定すること、欠陥ノードが3%未満という極端な不均衡であること。形式的には、各ノードが座標と正規化応力を持つメッシュグラフ上でノード分類器を学習し、focal loss を最小化します。クラス0は欠陥なし、1~18が領域×層を符号化します。

Slide 7 — Related work

To place the work in the literature, we have two anchors, both published in Composites Part B. Kojima twenty-twenty-five is the direct surface-stress lineage we build on, and indeed a co-author. PIGMID twenty-twenty-six is an adjacent physics-informed graph network, but it operates on guided-wave sensor signals — a different modality entirely. We differentiate ourselves on the input, the structure, the physics prior, and crucially an out-of-distribution generalization study: we are the first to quantify that detection transfers across defect size and position, while precise localization collapses.

【和訳】文献上の位置づけとして、2つの基準があり、いずれも Composites Part B 掲載です。児嶋 2025 は我々が土台とする表面応力の直系で、共著者でもあります。PIGMID 2026 は隣接する物理情報グラフ

ネットですが、ガイド波センサ信号という全く別のモダリティを扱います。我々は入力・構造・物理事前分布、そして決定的に分布外汎化の研究で差別化します：欠陥のサイズと位置をまたいで検出は転移するが、精密な位置標定は破綻する、ということを初めて定量化しました。

Slide 8 — FEM analysis conditions

We build the dataset by finite-element analysis. The model is a one-eightieth-scale curved interstage panel, about two meters in radius, with two rectangular holes. Delaminations are modeled explicitly, by inserting thin Teflon sheets between selected plies, under tensile loading. This gives us DSPSS fields with exactly known, ground-truth defect locations. In total we have one reference plus one thousand three hundred eighty-six defect specimens, evaluated with five-fold cross-validation.

【和訳】データセットは有限要素解析で構築します。モデルは 1/80 スケールの曲面段間パネル、半径約 2 メートル、矩形孔が 2 つ。層間剥離は、選んだ層間に薄いテフロンシートを挿入することで明示的にモデル化し、引張荷重下で解析します。これにより、欠陥位置が正確に既知の DSPSS 場が得られます。合計で参照 1 つ+欠陥試験体 1386 個、5 分割交差検証で評価します。

Slide 9 — Input: difference / normalized DSPSS

Now the input processing, which turns out to be essential. The raw DSPSS is dominated by the stress concentration around the holes, and that completely masks the defect. So we subtract a defect-free reference to obtain a difference field, and then z-score normalize it per node. This isolates the defect signal, and — importantly — it improves discrimination in the depth direction, that is, which layer the defect actually sits in. The result is robust localization even right next to the opening.

【和訳】次に入力処理で、これが本質的に重要です。生の DSPSS は孔まわりの応力集中に支配され、欠陥を完全に覆い隠します。そこで欠陥なし参照を差し引いて差分場を得て、ノードごとに z スコア正規化します。これにより欠陥信号が分離され、重要なことに深さ方向 — 欠陥がどの層にあるか — の識別が向上します。結果として、孔のすぐ隣でも頑健な位置標定が可能になります。

Slide 10 — Stress distribution around the defect

Looking more closely, each defect produces a stress valley at its center. But the depth and width of that valley depend on the ply angle of the layer directly above it: ninety-degree plies give sharp, narrow valleys, while zero and forty-five degree plies broaden them. This ply-angle signature is exactly the cue the network uses to infer which layer the delamination is in. It is a fine spatial-frequency problem, and that is precisely what motivates using local attention.

【和訳】より詳しく見ると、各欠陥は中心に応力の谷を生みます。ただしその谷の深さと幅は、直上の層の繊維角度に依存します：90 度層は鋭く狭い谷を、0 度や 45 度層は谷を広げます。この繊維角度のシグネチャこそ、ネットワークが層を推定する手がかりです。これは細かい空間周波数の問題であり、まさに局所アテンションを使う動機になります。

Slide 11 — Graph representation & GAT model

Here is the model. We represent each surface element as a node, with features being its coordinates and the normalized stress, and the edges are the fixed mesh connectivity, which is reused across all specimens. On this graph we use a graph attention network: three GAT layers, sixty-four up to two hundred fifty-six channels, multi-head attention, with batch normalization, dropout, and residual connections. The attention mechanism lets each node weight its neighbors adaptively, which is well suited to this highly non-uniform stress field.

【和訳】これがモデルです。各表面要素をノードとし、特徴はその座標と正規化応力、エッジは固定のメッシュ接続で、全試験体で再利用します。このグラフ上にグラフアテンションネットワークを用います：GAT 3 層、チャンネル 64~256、マルチヘッドアテンション、バッチ正規化・ドロップアウト・残差接続つき。アテンション機構により各ノードが近傍を適応的に重み付けでき、この極めて不均一な応力場に適しています。

Slide 12 — Output: 19-class node labels

We formulate localization as node classification into nineteen classes. Class zero is defect-free, and the remaining classes jointly encode the in-plane region and the insertion layer. We deliberately label only one side, so that prediction needs only a single-surface measurement, as it would in practice. And I want to emphasize the severe class imbalance: defect nodes are under three percent of all nodes, which we handle with the loss function on the next slide.

【和訳】位置標定を 19 クラスのノード分類として定式化します。クラス 0 は欠陥なし、残りのクラスが面内領域と挿入層を同時に符号化します。意図的に片面のみラベル付けし、予測が実運用と同様に片面測定のみで済むようにします。そして強調したいのが深刻なクラス不均衡：欠陥ノードは全体の 3%未満で、これは次スライドの損失関数で対処します。

Slide 13 — Loss function: Focal loss

To handle that imbalance, we use the focal loss. It down-weights the easy, abundant defect-free nodes, and focuses learning on the rare defect classes. This is crucial: without it, the model simply learns to predict defect-free everywhere, because intact regions make up more than ninety-seven percent of the data.

【和訳】その不均衡に対処するため、focal loss を用います。これは容易で大量な欠陥なしノードの重みを下げ、稀な欠陥クラスへ学習を集中させます。これは決定的に重要です：これがないと、健全領域がデータの 97%超を占めるため、モデルは至る所で欠陥なしと予測するだけになってしまいます。

Slide 14 — Results: prediction accuracy

Now the results, on held-out test specimens. We obtain a planar score R of zero point seven two, a depth score of zero point six nine, and a combined score, TDPS, of zero point seven zero — reaching zero point nine two in the best case. The mid-thickness layers, nine through twelve, are localized best. And critically, the false-negative rate on defect nodes is under three percent, so we very rarely miss a real defect — which is exactly the property you want for a safety inspection.

【和訳】次に結果で、未知のテスト試験体上です。面内スコア R が 0.72、深さスコアが 0.69、統合スコア TDPS が 0.70 — 最良で 0.92 に達します。板厚中央の層、9~12 が最もよく標定できます。そして決定的に、欠陥ノードの偽陰性率は 3%未満で、実欠陥を見逃すことはほとんどありません — これは安全検査でまさに求められる性質です。

Slide 15 — Overall performance & confusion

Aggregated over all nineteen classes, the overall macro-F1 is sixty-one percent, from surface DSPSS alone. The confusion matrix shows a strong diagonal. The residual errors are mostly confusion with the immediately adjacent layer, and the false positives tend to cluster near the hole edge, where the stress gradients are steepest. Performance is otherwise robust across the different defect insertion regions.

【和訳】全 19 クラスで集計した総合 macro-F1 は 61%で、表面 DSPSS のみからです。混同行列は強い対角を示します。残差誤差の大半は直近接層との混同で、偽陽性は応力勾配が最も急な孔縁付近に集まる傾向があります。それ以外では、異なる欠陥挿入領域をまたいで性能は頑健です。

Slide 16 — Conclusion

To summarize the published work: we introduced a finite-element-plus-graph-attention framework that localizes three-dimensional delamination in perforated CFRP interstage panels. The difference-normalized DSPSS input removes the hole stress concentration and enables full-region estimation. And we reach sixty-one percent macro-F1 over nineteen classes from surface data alone, with a very low defect false-negative rate, and no false detections in healthy regions. This is a scalable foundation toward experimental infrared-stress data and practical structural health monitoring.

【和訳】 既発表の成果をまとめます：孔あき CFRP 段間パネルの 3 次元層間剥離を標定する、有限要素＋グラフアテンションの枠組みを導入しました。差分正規化した DSPSS 入力がある孔の応力集中を除去し、全領域推定を可能にします。そして表面データのみで 19 クラスの macro-F1 61%を達成し、欠陥の偽陰性率は非常に低く、健全領域での誤検出はゼロです。これは実験的な赤外応力データと実用的な構造ヘルスマニタリングへ向けた、拡張可能な基盤です。

Slide 17 — New focus: robustness

Now I turn to the new part for this congress. The published model assumes clean finite-element fields. But real infrared measurements always carry noise — temperature drift, emissivity variation, sensor noise. And in practice almost the entire structure is healthy, which means false alarms are very costly. So here we focus on two things: robustness under realistic noise, and explicit suppression of false detection. On the right, you can see the input with and without injected noise — the defect signature still survives.

【和訳】 ここから本会議向けの新規部分に移ります。既発表のモデルはクリーンな有限要素場を仮定します。しかし実際の赤外測定には常にノイズが伴います — 温度ドリフト、放射率の変動、センサノイズ。そして実運用ではほぼ全構造が健全なので、誤警報は非常に高くつきます。そこで 2 点に注力します：現実的なノイズ下での頑健性と、誤検出の明示的な抑制。右図は、ノイズを注入した入力と無しの比較 — 欠陥のシグネチャは依然として残っています。

Slide 18 — Noise-augmented dataset & NDF

We do two things to achieve that. First, defect-free negatives, which we abbreviate NDF: we add five thousand training samples that are simply a zero field plus Gaussian noise, at ten percent of the data standard deviation. This explicitly teaches the model what no-defect looks like. Second, we add structured noise to the defect data — line noise along the fiber direction, attenuated noise across it, and global white noise — to mimic real measurement artifacts.

【和訳】 それを実現するため 2 つを行います。第一に、欠陥なし負例（NDF と略す）：ゼロ場にデータ標準偏差の 10%のガウスノイズを加えた学習サンプルを 5000 個追加します。これによりモデルに「欠陥がない」状態を明示的に教えます。第二に、欠陥データへ構造化ノイズを加えます — 繊維方向に沿った線状ノイズ、それと直交方向の減衰ノイズ、そして全体の白色ノイズ — 実測定のアーティファクトを模倣します。

Slide 19 — Results under noise

And the outcome. With the difference-DSPSS input, the model still estimates defects across the full region, and prediction stays accurate even on noise-injected data. The defect-free negatives remove spurious activations, so we obtain essentially no false detection on healthy inputs. In the example here, the noisy input on the left still yields the correct target localization on the right. Together, this makes the framework robust enough to begin moving toward real experimental data.

【和訳】そして結果です。差分 DSPSS 入力により、モデルは全領域で欠陥を推定し続け、ノイズ注入データ上でも予測精度を保ちます。欠陥なし負例が偽の活性化を除去するので、健全入力ではほぼ誤検出なしです。この例では、左のノイズ入力でも右の正しい標的位置標定が得られています。これらにより、枠組みは実験データへ進み始めるのに十分頑健になります。

Slide 20 — Outlook

Looking ahead, there are three directions. First, sim-to-real: applying this noise-robust model to actual infrared-stress, or TSA, measurements. Second, and still preliminary, we are extending from attention GNNs to mesh-physics GNNs, such as MeshGraphNet and some layered variants; the early results are encouraging and currently under evaluation with our co-authors. And third, transferring the approach to other perforated or bonded CFRP structures — rocket motor cases, aircraft wing boxes, satellite panels, and payload-fairing structural health monitoring.

【和訳】今後は 3 つの方向があります。第一に sim-to-real：このノイズ頑健モデルを実際の赤外応力 (TSA) 測定に適用すること。第二に、まだ予備的ですが、アテンション GNN からメッシュ物理 GNN —— MeshGraphNet や層構造の変種 —— へ拡張中で、初期結果は有望で、共著者と評価中です。第三に、本手法を他の孔あき・接着 CFRP 構造へ転用すること —— ロケットモータケース、航空機の主翼ボックス、衛星パネル、ペイロードフェアリングの構造ヘルスマニタリングです。

Slide 21 —Acknowledgements

This work was carried out in collaboration with JAXA, with co-authors at Keio University, Nagoya University, and JAXA, and it builds on the finite-element CFRP interstage dataset of the prior study. Thank you very much for your attention, and I am very happy to take your questions.

【和訳】本研究は JAXA との共同で実施し、共著者は慶應義塾大学・名古屋大学・JAXA に在籍、先行研究の有限要素 CFRP 段間データセットを土台としています。ご清聴どうもありがとうございました。喜んでご質問をお受けします。
